

AI暴露度计算Git代码仓库说明文档

1. 项目概述


项目名称: AI曝光度计算系统 (ai-exposure-calculation)

研究领域: 人工智能在学术研究中的应用评估、科学计量学、知识图谱构建

核心目标: 开发一套自动化的学术论文分析系统，评估AI技术在能源转型与气候变化相关研究中的使用程度、不可替代性及技术成熟度。

2. 技术架构

2.1 系统整体架构



2.2 核心模块职责

模块名称	文件路径	核心功能
AIExposureCalculator	AIExposureCalculator.py	主控调度，三阶段论文解析流程
ThemeDBBuilder	ThemeDBBuilder.py	主题知识库构建，AI技术库初始化
ThemeExtractor	ThemeExtractor.py	递归主题分类与评分算法
AIExposureMapper	AIExposureMapper.py	Neo4j图数据库Cypher查询封装
ThemesJudgePromptParser	ThemesJudgePromptParser.py	主题相关性LLM判断

3. 核心算法流程

3.1 三阶段论文处理流水线

阶段一：论文初筛与结构化解析

处理步骤：

综述论文过滤 (FilterReviewPaper)

1.
 - a. 基于LLM判断论文是否为综述类文献
 - b. 综述论文直接跳过后续分析

主题分类 (可选)

1.
 - a. **OpenAlex主题库**：四级分类体系 (Domain → Field → Subfield → Topic)
 - b. **基金委主题库**：三级分类体系 (Domain → Field → Subfield)
 - c. 使用递归深度优先搜索 + LLM评分进行主题匹配

宏观研究范式判断 (MacroParadigm)

1.
 - a. 定性研究 vs 定量研究

核心研究问题提取 (CoreResearchQuestion)

1.
 - a. 提取论文核心研究问题
 - b. 判断是否与“能源转型”或“气候变化”相关
 - c. 非相关论文直接过滤

科研任务环节映射 (ResearchTaskPhaseMapping)

1.
 - a. 三个核心环节的识别与评估：
 - i. data_and_material_collection_and_preprocessing
 - ii. modeling_or_analysis_framework_construction
 - iii. data_analysis_and_interpretation
 - b. 每个环节评估：内容描述、重要性排名(1-3)、工具方法、AI方法识别

2. 历史方法库构建

- a. 对未使用AI的论文，将其工具方法向量化存入FAISS数据库
- b. 用于后续对比分析

阶段二：AI使用度与不可替代性评估

关键指标计算：

AI使用度 (ai_usage_rate):

- 1.
 - a. 基于使用AI的研究环节比例

AI不可替代性评分 (ai_irreplaceable_score):

- 1.
 - a. 评估AI方法在各研究环节的必要性程度
 - b. 使用 AIRoleAssessment 模板

AI依赖类型:

- 1.
 - a. `fully_based` : 核心方法论完全基于AI
 - b. `partially_based` : 仅在特定环节使用AI

AI必要性分类:

- 1.
 - a. `indispensable` : 无AI则研究目标不可实现
 - b. `enhancement` : AI仅作为效率增强工具

阶段三：AI原生研究方案设计

创新分析维度:

AI原生解决方案设计 (DesignAINativeSolution)

- 1.
 - a. 为研究问题设计完全基于AI的研究方案

方案可行性评估 (AIReplacementJudge)

- 1.
 - a. `complete_replacement` : AI可完全替代传统实验
 - b. `partial_replacement` : AI可部分替代
 - c. `no_replacement` : AI无法替代

AI方案任务环节映射 (AIDesignResearchTaskPhaseMapping)

- 1.
 - a. 评估AI原生方案各环节的AI方法重要性评分

4. 知识图谱构建

4.1 主题分类体系

OpenAlex主题树（五级层次结构）：

1 Task → Domain → Field → Subfield → Topic → Theme

基金委主题树（三级层次结构）：

1 Task → Domain → Field → Subfield

4.2 AI技术库构建

技术成熟度计算算法（见ThemeDBBuilder.py:190–193）：

```
1 # 累积求和归一化
2 tech_maturity_values = [sum([x for x in year_num_mapping.values()][:i+1]
3                             for i in range(len(year_num_mapping)))]
4 tech_maturity_values = [x / max(tech_maturity_values) for x in tech_matu
```

技术实体属性：

- `en_name` / `zh_name`：中英文名称
- `core_function`：核心功能
- `research_application`：研究应用
- `tech_maturity_mapping`：年份–成熟度映射
- `keyword_list`：技术关键词列表（用于向量检索）

5. LLM提示工程体系

5.1 提示模板架构

项目采用结构化提示工程，共11个专用提示模板：

模板名称	输入	输出	用途
FilterReviewPaper	标题+摘要	判断+理由	过滤综述论文
MacroParadigm	标题+摘要	判断+理由	研究范式分类
CoreResearchQuestion	标题+摘要	问题+相关性	提取核心问题
ResearchTaskPhaseMapping	标题+摘要	三环节映射	任务环节识别
AIRoleAssessment	标题+摘要	必要性+使用级别	AI角色评估
AITechCreate	英文名称	中文名称+功能	AI技术实体生成
GenerateDomainKeywords	领域列表	关键词列表	技术关键词扩展
DesignAINativeSolution	研究问题	完整方案	AI方案设计
AIReplacementJudge	原方法+新方法	替代级别	替代可行性评估
AIResearchTaskPhaseMapping	设计方案	三环节映射	AI方案任务映射
AIDesignResearchTaskPhaseMapping	研究问题	方案+映射	端到端方案设计

5.2 提示工程特点

- 1. Few-shot Learning：每个模板包含详细的输出示例
 - 2. Schema约束：配套JSON Schema定义输出格式
 - 3. 多语言支持：支持中英文输入，英文提示模板
 - 4. 重试机制：LLM调用失败自动重试（见ThemesJudgePromptParser:52-63）
-

6. 数据存储架构

6.1 存储层次

存储类型	技术选型	存储内容
图数据库	Neo4j	主题树、AI技术实体、关系网络
向量数据库	FAISS	工具方法向量、AI技术关键词向量
结构化数据	CSV	论文解析结果、中间数据
配置/元数据	JSON	任务信息、技术成熟度映射

6.2 向量检索机制

FAISS索引配置：

- 索引类型：flat_ip （内积相似度）
 - 向量维度：1024（可配置）
 - 距离阈值：0.5（用于相似性匹配）
-

7. 关键技术创新点

7.1 递归主题分类算法

```
1 # 见ThemeExtractor.py:44-86
2 def recursion_fetch_and_rank(self, node_idx, value, paper_title, paper_a
3     # 1. 从图数据库获取候选子主题
4     neo4j_result = AIExposureMapper.match_next_nodes(...)
5
6     # 2. LLM评分每个候选主题的相关性
7     themes_judge_result = ThemesJudgePromptParser.process(...)
8
9     # 3. 基于平均分阈值筛选
10    avg_score = sum([x["score"] for x in themes_judge_result.values()])
11    chosen_theme_list = {k: v for k, v in themes_judge_result.items()
12                        if v["score"] >= avg_score and v["score"] >= 5}
13
14    # 4. 递归处理子主题
15    for theme_name in chosen_theme_list:
16        self.recursion_fetch_and_rank(node_idx+1, theme_name, ...)
```

7.2 多维度AI评估指标体系


评估维度：

- 1. AI使用度：使用AI的环节比例
- 2. AI不可替代性：indispensable vs enhancement
- 3. AI依赖深度：fully_based vs partially_based
- 4. AI技术成熟度：基于时间累积的归一化指标
- 5. AI替代潜力：complete/partial/no replacement

7.3 Checkpoint机制

- 增量处理：支持断点续传 (resume=True)
- 批量写入：每N行写入一次 (checkpoint_rows)
- 分片存储：大文件自动分割 (max_rows_per_file)

8. 系统工作流程



```
graph TD; A[阶段二：AI评估] --> B[阶段三：AI方案设计];
```

The diagram illustrates a two-stage process:

- Stage 2: AI Evaluation (阶段二：AI评估)**
 - For each paper (使用AI的):
 - AI使用度计算
 - AI不可替代性评分
 - AI依赖类型判断 (fully/partially based)
 - AI必要性判断 (indispensable/enhancement)
- Stage 3: AI Solution Design (阶段三：AI方案设计)**
 - For each paper:
 - 设计AI原生研究方案 (DesignAINativeSolution)
 - 评估AI方案可行性 (AIReplacementJudge)
 - 映射AI方案任务环节 (AIDesignResearchTaskPhaseMapping)

9. 技术依赖

9.1 核心依赖库

库名称	用途
wd_basekit	基础工具库（配置、日志、LLM API、数据库驱动等）
pandas	数据处理与分析
faiss	向量检索
neo4j	图数据库
python-docx	Word文档解析
tqdm	进度条

9.2 LLM集成

- 支持通义千问 (Qwen) 系列模型
- 通过 `LLMAPIClient` 统一调用接口
- 支持嵌入向量生成

10. 学术贡献与应用价值

10.1 方法论创新

1. **多维度AI应用评估框架**：首次系统性地从使用度、不可替代性、依赖深度等多角度评估学术研究中的AI应用
2. **自动化文献分析流水线**：将传统文献计量学与LLM语义理解相结合
3. **AI技术成熟度量化模型**：基于时间序列的技术成熟度评估方法

10.2 应用场景

1. 科研政策制定：评估AI技术对能源转型/气候变化研究的影响
2. 研究方向评估：识别AI在特定学科领域的渗透程度
3. 学术出版：辅助审稿人评估论文的AI技术创新性
4. 科研管理：为AI相关研究项目的立项提供数据支撑

10.3 研究局限性

1. 数据依赖：分析结果受限于输入论文的质量和数量
 2. LLM不确定性：LLM判断存在一定的主观性和不确定性
 3. 领域适用性：当前系统主要针对能源转型与气候变化领域
-

11. 代码质量与工程实践

11.1 设计模式

- 工厂模式： `AIExposureCalculator.run()` 作为统一入口
- 策略模式：不同LLM模板可灵活替换
- 数据映射器模式： `AIExposureMapper` 封装数据库操作

11.2 可维护性

- 模块化设计，职责清晰
- 配置与代码分离
- 完善的日志记录
- 异常处理与容错机制

11.3 可扩展性

- 提示模板易于扩展
 - 支持多种主题分类体系
 - 向量数据库可替换
-

12. 总结

该项目构建了一套完整的AI技术在学术研究中应用程度的自动化评估系统，融合了知识图谱、向量检索、LLM语义理解等前沿技术，为科学计量学研究提供了新的方法论和工具支持。系统的三阶段流水线设计、多维度评估指标体系以及AI原生研究方案生成能力，使其在AI与科研交叉领域具有重要的学术价值和应用潜力。